浙江大学

ZHEJIANG UNIVERSITY

“智学引擎”智能学习助手系统

项目计划书

组　长　陈子涵

组　员　邓佳骏 郭云海 方李庭 魏文俐

日　期　2025.10.17

Contents

1 引言 **1**

1.1 项目背景 1

1.2 编写目的 1

1.3 软件系统名称 1

1.4 相关人员 1

1.5 读者对象 2

2 项目概况 **2**

2.1 前言介绍 2

2.2 项目介绍 2

2.3 名词介绍 3

2.4 产品成果 3

2.4.1 产品 3

2.4.2 手册 3

2.4.3 服务 4

3 成本估计 **4**

3.1 硬件成本 4

3.2 其他成本 4

4 开发技术分析 **4**

4.1 开发技术栈 4

4.2 技术分析 5

5 开发进度计划 **5**

6 角色分配 **6**

7 参考文献 **7**

1 引言

1.1 项目背景

在高校与自学场景中，学习资料往往来源多样、格式各异，我们需要在书本、课件、复习大纲与笔记之间频繁切换。由此带来的信息碎片化，使得梳理知识脉络与高效回忆变得困难。传统检索与问答工具难以结合课程上下文提供连贯的解答，且回答过程缺乏来源标注，可信度不足。

检索增强生成的技术路径已较为成熟：通过对学习资料进行加载、切分、嵌入并构建索引，可在提问时检索最相关的片段，再与问题一并交给大语言模型合成回答。借助重排序模型对初步检索结果进行二次筛选，可以提升上下文的相关性；在回答末尾附上来源指引，则可以显著增强可追溯性，降低编造风险。

在上述背景下，本项目以课程与相关资料为核心对象，构建一个能够理解资料、辅助梳理与自我检测的智能学习伙伴，通过问答中心与资料中心协同工作，支持高质量、可溯源的解答以及针对单份文档的摘要与测验生成，推动从被动阅读向主动学习转变。同时，集成外部学术搜索引擎 API，为用户提供基于关键词的实时文献检索功能，将学习助手的知识边界由课内扩展到学术领域。

1.2 编写目的

本文件旨在清晰、全面地阐述“智学引擎”智能学习助手系统的整体规划。

- **明确项目目标与范围**：定义项目的核心功能、技术边界和最终交付成果。
- **统一团队认知**：为项目所有参与者提供一份共同的、标准化的行动纲领。
- **指导项目开发**：作为后续需求分析、系统设计、编码实现和测试验收等阶段的指导性文件。
- **沟通与汇报**：作为与课程老师、助教沟通项目进展、展示项目规划的核心依据。

1.3 软件系统名称

- **中文名称**：“智学引擎”智能学习助手
- **英文名称**: Smart Learning Engine (SLE)

1.4 相关人员

- **任务提出方**: 软件工程管理课程组

- **项目开发方**: 软件工程管理第 9 小组全体成员
- **最终用户**: 广大在校学生、学习者及任何需要进行知识管理与学习的个人

1.5 读者对象

- **课程老师、助教**: 审阅项目的技术可行性、工作量评估及计划合理性。
- **项目开发团队成员**: 理解各自的角色职责、开发任务和进度安排。
- **未来可能的项目维护者**: 便于理解系统架构和设计思路，进行后续维护与迭代。

  读者宜具备以下预备知识：基本的计算机与软件工程概念，Web 前端与后端的基础认知（如 HTTP/API 与前后端分工的常识），版本控制与协作的基本操作，以及基于向量检索与大语言模型的基础概念（RAG、嵌入、向量检索与重排的作用）。

2 项目概况

2.1 前言介绍

“智学引擎”项目源于对现代学习方式的深度思考，旨在利用前沿的 AI 技术，将静态的学习资料转化为一个动态的、可交互的智能知识库。我们注意到，尽管现有学习工具众多，但大多停留在“资料存储”或“简单搜索”层面，缺乏对知识内容本身的深度理解和智能化的处理能力。本项目致力于弥补这一鸿沟，打造一个真正懂学习、会辅助的智能伙伴。

2.2 项目介绍

“智学引擎”是一个基于大语言模型的全栈 Web 应用。它的核心功能是允许用户上传并建立一个私有的、本地化的学习资料库，并通过一个统一的、智能化的平台与这些资料进行深度互动。系统不仅能基于整个知识库提供精准、可溯源的问答，还集成了一系列 AI 辅助学习工具，如智能摘要、自动测验、划词精准问答和外部学术文献检索，旨在构建一个从知识输入、理解、巩固到拓展的全链路智能学习闭环。

系统提供两个核心入口：

其一为“智能问答中心”，提供流畅的对话体验，回答严格基于知识库，并在答案末尾附上来源标签，支持在问题模糊时仍能凭借重排模型找到更相关的上下文；

其二为“学习资料与 AI 工具中心”，集中展示知识库文档列表，并为每份资料提供“一键生成摘要”“一键生成测验”等工具，用户可在阅读文档时就局部内容发起上下文精准问答。同时，设置“学术文献检索”模块，集成外部学术搜索引擎 API，为用户提供基于关键词的实时文献检索功能，将学习助手的知识边界由课内扩展到学术领域。

2.3 名词介绍

RAG (Retrieval-Augmented Generation)

检索增强生成。一种先进的 AI 架构，它将信息检索系统与大语言模型相结合，让模型在回答问题前，先从指定的知识库中检索相关信息作为上下文，从而生成更准确、更可信的答案。

LlamaIndex

一个领先的数据框架，专门用于简化 RAG 应用的构建，负责连接数据源和大型语言模型。

FastAPI

一个现代、高性能的 Python Web 框架，用于构建本项目的后端 API 服务。

Next.js

一个基于 React 的 Web 开发框架，用于构建本项目的用户界面，提供优秀的性能和开发体验。

Vector Store (向量数据库)

一种专门用于存储和查询向量（文本的数学表示）的数据库，是实现高效语义检索的核心。

Reranker (重排序模型)

一种 AI 模型，用于对初步检索结果进行二次优化筛选，提高最终上下文的精准度。

Semantic Scholar (语义学者)

一个由艾伦人工智能研究所开发的、基于 AI 的学术搜索引擎，本项目将通过其 API 实现外部文献检索。

2.4 产品成果

2.4.1 产品

- 一个功能完整的、可部署的 Web 应用，包含前端界面和后端服务。
- 完整的项目源代码，托管于 Git 仓库。

2.4.2 手册

- **项目计划书** (本文档)。
- **系统设计报告** (包含架构图、API 设计等)。

- **系统测试报告**。

2.4.3 服务

- 一个可供访问的在线演示版本（部署于云服务器）。

3 成本估计

3.1 硬件成本

本项目主要基于现有个人计算机设备进行开发，无特殊硬件需求。服务器部署阶段将使用云服务提供商（如 Vercel, Railway 等）的免费额度，因此硬件成本预估为 **0**。

3.2 其他成本

- **人力成本**: 无。
- **软件成本**:
  - **开发工具**: 所用编程语言 (Python, TypeScript)、框架 (FastAPI, Next.js) 及数据库均为开源免费软件。
  - **API 调用费用**: 项目将使用大语言模型 API (如 OpenAI GPT 系列)。在开发和测试阶段，预计会产生少量 API 调用费用，预估在 **10-20 美元**范围内。

4 开发技术分析

4.1 开发技术栈

- **前端技术栈**:
  - **框架**: Next.js (基于 React.js)
  - **语言**: TypeScript
  - **UI 库**: shadcn/ui (基于 Radix UI)
  - **样式**: Tailwind CSS
- **后端技术栈**:
  - **框架**: FastAPI
  - **语言**: Python

  - **AI 核心**: LlamaIndex

- **数据库**:
  - **向量存储**: LlamaIndex 内置的 ‘SimpleVectorStore‘ (基于文件)
- **代码管理和协作开发工具**:
  - Git, GitHub
- **文档管理**:
  - 飞书, overleaf, Microsoft Office Word
- **测试工具**:
  - Postman (用于 API 测试)

4.2 技术分析

- **前后端分离架构**: 我们采用业界主流的前后端分离架构。前端 Next.js 负责用户界面和交互逻辑，后端 FastAPI 负责业务逻辑、数据处理和 AI 能力封装。两者通过 RESTful API 进行通信，这种架构使得团队分工明确、开发并行、系统易于维护和扩展。
- **LlamaIndex 框架的选用**: LlamaIndex 极大地简化了构建复杂 RAG 应用的难度。它屏蔽了数据加载、分块、向量化、索引和查询等底层细节，使我们能将开发重点聚焦于业务逻辑和功能创新，而非一味重复。
- **FastAPI 的优势**: 其天生的异步支持对于处理 AI 模型的流式响应至关重要，能为用户带来流畅的问答体验。同时，其高性能和低资源消耗的特点也适合学生项目的部署。
- **Git 进行版本控制**: 使用 Git 和 GitHub 进行协作开发，可以有效地管理代码版本、处理多人协作时的代码冲突，并记录项目的完整开发历史。

5 开发进度计划

Table 1: 开发进度计划表

项目阶段	时间	负责人	主要工作	输出内容
项目选定与启动	1 天	组长	确定项目选题，建立沟通渠道	选题
需求分析与规划	3 天	全体成员	讨论并明确项目范围、核心功能，完成项目计划书	项目计划书 (本文档)、开题 ppt
第一周：基础构建	1 周	全体成员	搭建项目框架，实现基于固定知识库的高质量问答 MVP	可运行的基础版应用
第二周：资料中心	1 周	全体成员	开发学习资料中心页面，实现内部知识库内容展示	学习资料中心前端页面及 API
第三周：AI 工具集	1 周	全体成员	开发智能摘要和智能测验两大核心 AI 功能并联调	AI 工具集前端 UI 及 API、系统测试文档与 ppt
第四周：交互体验	1 周	全体成员	开发划词精准问答功能，创建文档阅读器页面	文档阅读器及交互式问答功能
第五周：开放域拓展	1 周	全体成员	集成 Semantic Scholar API，实现学术文献检索	学术文献检索模块
系统测试与部署	4 天	全体成员	进行全面的功能测试、性能测试，修复 Bug，部署上线	系统测试报告，在线演示 URL
文档撰写与总结	3 天	全体成员	撰写用户手册、总结报告，制作答辩 PPT	完整的项目文档和汇报 PPT

6 角色分配

Table 2: 角色分配表

编号	角色	角色职责	具体负责人
1	项目经理/组长	负责项目整体规划、进度跟踪、团队协调和最终决策。	陈子涵

表 2 – 续前页

编号	角色	角色职责	具体负责人
2	产品经理	负责需求分析、功能设计和用户体验把控。	方李庭, 魏文俐
3	后端开发工程师	负责 FastAPI 后端服务开发、AI 核心逻辑实现、API 接口设计与开发。	陈子涵, 邓佳骏, 郭云海
4	前端开发工程师	负责 Next.js 前端页面开发、UI 组件实现、与后端 API 的联调。	方李庭, 魏文俐
5	测试与文档工程师	负责编写测试用例、执行系统测试、撰写项目相关文档。	全体成员

7 参考文献

(1). Lewis, P., et al. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. *Advances in Neural Information Processing Systems, 33*.

(2). Vaswani, A., et al. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems, 30*.

(3). Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics*.

(4). Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*.

(5). Ammar, W., et al. (2018). Construction of the Literature Graph in Semantic Scholar. *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*.

(6). Liu, J. (2022). LlamaIndex: A data framework for LLM applications. *GitHub repository*. https://github.com/run-llama/llama_index

(7). BAAI. (2023). BGE Reranker Model Card. *Hugging Face*. https://huggingface.co/BAAI/bge-reranker-base

(8). FastAPI. (n.d.). FastAPI Web Framework. https://fastapi.tiangolo.com/